

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Atelier Pratique : E-commerce de Cadeaux

Préparé par Ranim Bouguila

Année Universitaire : 2025-2026

Table des matières

1	Introduction	5
2	Architecture du Pipeline	5
2.1	Variables RFM (comportement d'achat)	5
2.2	Variables Produit	5
2.3	Variables Client	6
3	Étapes du Prétraitement	6
3.1	Étape 1 — Chargement et Analyse Initiale	6
3.2	Étape 2 — Nettoyage de Base	6
3.3	Étape 3 — Valeurs Aberrantes et Sentinelles	6
3.4	Étape 4 — Formats Inconsistants et Feature Engineering	7
3.5	Étape 5 — Encodage des Variables Catégorielles	7
3.6	Étape 6 — Split Train/Test et Normalisation	7
4	Résultats du Prétraitement	8
4.1	Observations Importantes	8
5	Clustering K-Means	8
5.1	Objectif	8
5.2	Features Utilisées	8
5.3	Sélection du Nombre de Clusters — Méthode Elbow	8
5.4	Résultats K-Means avec k=4	9
5.5	Interprétation des Clusters	9
6	Identification et Traitement du Data Leakage	10
6.1	Type 1 — Leakage Direct (colonnes calculées depuis Churn)	10
6.2	Type 2 — Leakage Indirect (corrélations artificielles)	10
6.3	Impact de la Correction	11
7	Classification — Prédiction du Churn	11
7.1	Objectif	11
7.2	Gestion du Déséquilibre	11
7.3	Importance des Features (XGBoost)	13
7.4	Interprétation	13
8	Régression — Prédiction de MonetaryTotal	13
8.1	Objectif	13
8.2	Colonnes Exclues	13
8.3	Résultats	14
8.4	Interprétation des Résultats	14
9	Prédiction et Déploiement des Modèles	14
9.1	Architecture du Script <code>predict.py</code>	14
9.1.1	Seuils de Risque Churn	15
9.2	Résultats sur le Jeu de Test (875 Clients)	16
9.2.1	Résultats de la Classification	16
9.2.2	Résultats de la Segmentation	17
9.2.3	Résultats de la Régression	17
9.3	Comparaison Churn Réel vs Prédit	18
9.4	Rapport Combiné — Extrait <code>predictions.csv</code>	18
9.5	Exemple de Prédiction pour un Nouveau Client	19

9.6	Limites et Recommandations pour le Déploiement	20
9.6.1	Limites Identifiées	20
9.6.2	Recommandations pour le Déploiement en Production	20

Table des figures

1	Pipeline complet de prétraitement	5
2	Traitement des valeurs aberrantes - Méthode IQR	6
3	éviter le data leakage	7
4	Courbe d'Elbow — sélection du k optimal (coude à k=4)	9
5	Segmentation K-Means — Recency vs MonetaryTotal (k=4)	10
6	Matrices de confusion des trois modèles	12
7	Top 10 des features les plus importantes pour la prédiction du churn	13
8	Régression Random Forest — Valeurs réelles vs prédites. La droite rouge représente la prédiction parfaite. Les points s'éloignant de la diagonale correspondent aux clients VIP.	14
9	Distribution des niveaux de risque Churn sur les 875 clients de test	16
10	Distribution des probabilités de churn — concentration aux extrêmes (nature synthétique du dataset)	16
11	Distribution des segments clients K-Means sur les 875 clients de test	17
12	Distribution des montants prédits par segment (clients avec montant > 0£)	18
13	Comparaison churn réel vs prédit — distributions quasi-identiques confirmant l'accuracy de 99.77%	18

Liste des tableaux

1	Résumé des transformations	8
2	Dataset final prêt pour la modélisation	8
3	Inertie par nombre de clusters	9
4	Profil des 4 clusters clients	9
5	Colonnes supprimées pour leakage direct	10
6	Colonnes supprimées pour corrélations artificielles	11
7	Comparaison avant/après suppression du leakage	11
8	Performances des modèles de classification	11
9	Top 5 features importantes (XGBoost)	13
10	Performances des modèles de régression	14
11	Modèles chargés par <code>predict.py</code>	15
12	Pipeline d'exécution de <code>predict.py</code>	15
13	Modèles chargés par <code>predict.py</code>	15
14	Pipeline d'exécution de <code>predict.py</code>	15
15	Seuils de risque Churn	15
16	Distribution des prédictions de churn	16
17	Distribution des niveaux de risque	16
18	Distribution des segments clients	17
19	Statistiques des montants prédits	17
20	Extrait des prédictions (10 premiers clients)	19
21	Caractéristiques du nouveau client (valeurs normalisées)	19
22	Résultats de prédiction pour le nouveau client	19
23	Limites du système de prédiction	20

1 Introduction

Ce projet vise à construire une chaîne complète de Machine Learning pour analyser le comportement des clients d'un e-commerce de cadeaux. Deux objectifs principaux :

- **Segmenter** la clientèle (VIP, clients dormants, nouveaux)
- **Prédire** le churn (départ des clients)

Ce rapport détaille la première phase : le **prétraitement des données**.

2 Architecture du Pipeline

Le pipeline de prétraitement se décompose en 6 étapes successives :




FIGURE 1 – Pipeline complet de prétraitement

2.1 Variables RFM (comportement d'achat)

- **Recency** : nombre de jours écoulés depuis le dernier achat (0-400 jours)
- **Frequency** : nombre de commandes distinctes passées (1-248)
- **MonetaryTotal** : dépense totale en livres sterling, peut être négative (remboursements), de -4287£ à +279489£

2.2 Variables Produit

- TotalQuantity, UniqueProducts, UniqueDescriptions
- ReturnRatio, CancelledTransactions, NegativeQuantityCount

2.3 Variables Client

- Age : 30% de valeurs manquantes (1311 NaN sur 4372)
- SupportTicketsCount et SatisfactionScore : contiennent des valeurs sentinelles (-1, 999, 0, 99) encodant des erreurs système
- Gender (M/F/Unknown), Region (13 régions), Country (37 pays)
- Churn : variable cible binaire (0=fidèle, 1=parti), taux=33.3%

3 Étapes du Prétraitement

3.1 Étape 1 — Chargement et Analyse Initiale

Diagnostic complet du dataset : types de données, statistiques descriptives, valeurs manquantes par colonne, doublons. **Résultat** : 0 doublon détecté. 2 colonnes avec NaN :

- Age : 1311 valeurs manquantes (30%)
- AvgDaysBetweenPurchases : 79 valeurs manquantes (1.8%)

3.2 Étape 2 — Nettoyage de Base

- Suppression des doublons : 0 supprimé
- Imputation de Age par la médiane (49.0 ans) — la médiane est préférée à la moyenne car robuste aux valeurs extrêmes
- Imputation de AvgDaysBetweenPurchases par la médiane

3.3 Étape 3 — Valeurs Aberrantes et Sentinelles

Deux types de problèmes distincts sont traités :

Type 1 — Valeurs sentinelles (codes d'erreur déguisés en nombres) :

- SupportTicketsCount : 130 valeurs -1 et 999 remplacées par NaN puis imputées par la médiane (2.0 tickets)
- SatisfactionScore : 349 valeurs -1, 0 et 99 remplacées par NaN puis imputées par la médiane (3.0/5)

Type 2 — Vraies valeurs aberrantes statistiques : Méthode IQR (Interquartile Range) appliquée sur SupportTicketsCount : bornes calculées $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR] = [-2.00, 6.00]$. 23 valeurs extrêmes ramenées aux bornes (capping).




FIGURE 2 – Traitement des valeurs aberrantes - Méthode IQR

3.4 Étape 4 — Formats Inconsistants et Feature Engineering

RegistrationDate : formats hétérogènes (DD/MM/YYYY, YYYY-MM-DD, etc.) convertis en datetime uniforme. 4 nouvelles features extraites : **RegYear**, **RegMonth**, **RegDay**, **RegWeekday**. La colonne date originale est ensuite supprimée.

LastLoginIP : adresse IP brute transformée en 5 features exploitables : **IP1**, **IP2**, **IP3**, **IP4** (4 octets numériques) et **IP_Type** (Private/Public selon les plages RFC 1918 : 10.x.x.x, 172.x.x.x, 192.x.x.x). Résultat : 4321 IPs publiques, 51 IPs privées.

NewsletterSubscribed : supprimée car variance nulle (toujours "Yes") — aucune information prédictive.

3.5 Étape 5 — Encodage des Variables Catégorielles

3 stratégies selon la nature de chaque colonne :

Encodage Ordinal (6 colonnes avec ordre logique) :

- **SpendingCategory** : Low=0, Medium=1, High=2, VIP=3
 - **AgeCategory** : Inconnu=0, 18-24=1, ..., 65+=6
 - **LoyaltyLevel** : Nouveau=0, Jeune=1, Établi=2, Ancien=3
 - **ChurnRiskCategory** : Faible=0, Moyen=1, Élevé=2, Critique=3
 - **BasketSizeCategory** : Petit=0, Moyen=1, Grand=2
 - **PreferredTimeOfDay** : Nuit=0, Matin=1, Midi=2, Après-midi=3, Soir=4
- Encodage One-Hot (8 colonnes sans ordre) :** **Gender**, **Region**, **AccountStatus**, **CustomerType**, **FavoriteSeason**, **WeekendPreference**, **ProductDiversity**, **IP_Type**. **drop_first=True** pour éviter la multicollinéarité. Résultat : 8 colonnes → 29 nouvelles colonnes binaires.
- Encodage par Fréquence (Country — 37 valeurs uniques) :** Chaque pays remplacé par sa proportion dans le dataset. Ex : United Kingdom → 0.904, France → 0.020, Germany → 0.022.

3.6 Étape 6 — Split Train/Test et Normalisation

Split stratifié 80/20 avec **random_state=42** pour la reproductibilité. **stratify=y** garantit que les proportions Churn/Non-Churn sont conservées dans les deux sous-ensembles.




FIGURE 3 — éviter le data leakage

StandardScaler appliqué uniquement sur `X_train` (`fit_transform`), puis transform sur `X_test` — règle absolue pour éviter le data leakage. La variable cible `y` n'est jamais normalisée.

4 Résultats du Prétraitement

TABLE 1 – Résumé des transformations

Opération	Résultat
Doublons	0 trouvés
Imputation Age	1311 valeurs → médiane 49.0
AvgDaysBetweenPurchases	79 valeurs → médiane
SupportTicketsCount	130 sentinelles + 23 outliers corrigés
SatisfactionScore	349 sentinelles corrigées
RegistrationDate	4 features extraites (Year, Month, Day, Weekday)
NewsletterSubscribed	Supprimée (variance nulle)
LastLoginIP	→ IP1, IP2, IP3, IP4, IP_Type
Encodage ordinal	6 colonnes encodées
Encodage One-Hot	8 colonnes → 29 nouvelles colonnes
Encodage fréquence	Country → Country_freq
Dimensions finales	4372 lignes × 81 colonnes

TABLE 2 – Dataset final prêt pour la modélisation

Fichier	Lignes	Colonnes
X_train.csv	3497	79
X_test.csv	875	79
y_train.csv	3497	1
y_test.csv	875	1

4.1 Observations Importantes

- **Taux de churn** : 33.3% (2918 non-churn / 1454 churn) → déséquilibre modéré, traité par `class_weight='balanced'` lors de la modélisation
- **Région** : 90.5% UK → déséquilibre géographique important
- **WeekendPreference** : 71.5% "Inconnu" → feature peu informative

5 Clustering K-Means

5.1 Objectif

Segmenter les clients en groupes homogènes selon leur comportement d'achat sans utiliser la variable cible `Churn` (apprentissage non supervisé).

5.2 Features Utilisées

`Recency`, `Frequency`, `MonetaryTotal` (déjà normalisées par `StandardScaler` lors du prétraitement).

5.3 Sélection du Nombre de Clusters — Méthode Elbow

On entraîne K-Means pour `k` de 2 à 9 et on mesure l'inertie intra-cluster. L'inertie décroît rapidement jusqu'à `k=4` puis se stabilise progressivement. Le "coude" identifié à `k=4` correspond aux 4 segments RFM du dataset.

TABLE 3 – Inertie par nombre de clusters

k	Inertie
2	7129
3	4254
4	3228
5	2428
6	1941




FIGURE 4 – Courbe d'Elbow — sélection du k optimal (coude à k=4)

5.4 Résultats K-Means avec k=4

Silhouette Score = 0.6041 (supérieur à 0.5 → bon clustering)

TABLE 4 – Profil des 4 clusters clients

Cluster	Taille	Recency	Frequency	Monetary	Interprétation
0	877	+1.54	-0.34	-0.19	Clients Dormants
1	2571	-0.51	+0.01	-0.04	Clients Réguliers
2	44	-0.86	+5.19	+3.54	Clients Champions
3	5	-0.83	+8.80	+21.12	Clients VIP Absolus

5.5 Interprétation des Clusters

- **Cluster 0 (Dormants, 20%)** : Recency élevée → n'ont pas acheté depuis longtemps. Fréquence et montant faibles. Risque de churn élevé.
- **Cluster 1 (Réguliers, 59%)** : comportement moyen équilibré. Cœur de clientèle stable.
- **Cluster 2 (Champions, 1%)** : achats très récents, très fréquents et montants élevés. Clients à fidéliser en priorité.
- **Cluster 3 (VIP, 0.1%)** : comportement extrême, dépenses 21× supérieures à la moyenne. Clients ultra-premium.




FIGURE 5 – Segmentation K-Means — Recency vs MonetaryTotal (k=4)

6 Identification et Traitement du Data Leakage

Lors de l'entraînement initial, les trois classificateurs atteignaient une accuracy de 100%, révélant un problème de **data leakage**.

6.1 Type 1 — Leakage Direct (colonnes calculées depuis Churn)

Certaines colonnes ont été construites algorithmiquement À PARTIR de la variable **Churn** lors de la génération du dataset synthétique.

TABLE 5 – Colonnes supprimées pour leakage direct

Colonne	Corrélation	Raison de suppression
ChurnRiskCategory	0.878	Encodage du risque de churn
CustomerType_Perdus	0.699	"Perdu" = churné par définition
RFMSegment_Dormants	0.573	Dormant = inactif = churné
LoyaltyLevel	0.429	Niveau de fidélité = inverse du churn
RFMSegment_Fidèles	0.300	Fidèle = non churné par définition
RFMSegment_Potentiels	0.299	Segment à risque de churn
CustomerType_Nouveaux	0.232	Corrélié fortement au churn

6.2 Type 2 — Leakage Indirect (corrélations artificielles)

La variable **Churn** a été générée algorithmiquement à partir de features temporelles, créant des corrélations irréalistes.

TABLE 6 – Colonnes supprimées pour corrélations artificielles

Feature	Corrélation	Décision
Recency	0.858	Supprimée pour classification
CustomerTenureDays	0.453	Supprimée
PreferredMonth	0.427	Supprimée
SpendingCategory	0.384	Supprimée
FavoriteSeason_Printemps	0.302	Supprimée
Frequency	0.217	Conservée (corrélacion acceptable)
UniqueInvoices	0.217	Conservée

Au total : **12 colonnes supprimées** → X passe de 79 à 67 features.

6.3 Impact de la Correction

TABLE 7 – Comparaison avant/après suppression du leakage

Modèle	Avant suppression	Après suppression
Logistic Regression	100%	98.29%
Random Forest	100%	98.51%
XGBoost	100%	99.77%

Conclusion Méthodologique

Les scores restent élevés (98-99%) car le dataset est synthétique et pédagogique — le Churn y a été généré par une formule déterministe.

Dans un dataset réel de e-commerce :

- Corrélations features/Churn seraient de 0.15 à 0.35
- Performances attendues : 75% à 88% d'accuracy
- Présence de bruit, cas ambigus, comportements imprévisibles

Ce problème illustre l'importance de :

1. Analyser les corrélations features/target avant entraînement
2. Identifier les colonnes construites depuis la target
3. Distinguer performances sur données synthétiques vs réelles

7 Classification — Prédiction du Churn

7.1 Objectif

Prédire si un client va partir (Churn=1) ou rester (Churn=0). Features : 67 colonnes après suppression du leakage.

7.2 Gestion du Déséquilibre

- Logistic Regression et Random Forest : `class_weight='balanced'`

subsectionRésultats

TABLE 8 – Performances des modèles de classification

Modèle	Accuracy	F1-Score	FP	FN
Logistic Regression	98.29%	0.9828	5	10
Random Forest	98.51%	0.9851	0	13
XGBoost	99.77%	0.9977	0	2




FIGURE 6 – Matrices de confusion des trois modèles

7.3 Importance des Features (XGBoost)




FIGURE 7 – Top 10 des features les plus importantes pour la prédiction du churn

TABLE 9 – Top 5 features importantes (XGBoost)

Feature	Importance
CustomerType_Occasionnel	18.7%
Frequency	15.6%
FirstPurchaseDaysAgo	14.5%
UniqueInvoices	11.5%
CustomerType_Régulier	6.5%

7.4 Interprétation

Les clients "Occasionnels" et la fréquence d'achat sont les meilleurs prédicteurs du churn. Un client qui achète rarement et depuis longtemps a un risque de départ significativement plus élevé.

8 Régression — Prédiction de MonetaryTotal

8.1 Objectif

Prédire le montant total dépensé par un client (valeur continue). Features : 42 colonnes numériques.

8.2 Colonnes Exclues

MonetaryAvg, MonetaryStd, MonetaryMin, MonetaryMax (toutes dérivées de MonetaryTotal → leakage de régression).

8.3 Résultats

TABLE 10 – Performances des modèles de régression

Modèle	MAE (£)	RMSE (£)	R ²
Linear Regression	819.82	6584.67	0.6630
Random Forest	688.07	6361.77	0.6855
XGBoost	825.50	7996.71	0.5030




FIGURE 8 – Régression Random Forest — Valeurs réelles vs prédites. La droite rouge représente la prédiction parfaite. Les points s'éloignant de la diagonale correspondent aux clients VIP.

8.4 Interprétation des Résultats

- **R² = 0.6855** : le modèle explique 68.55% de la variance du montant dépensé — performance correcte pour ce type de données
- **RMSE élevé (6361£)** : s'explique par la présence de clients VIP (Cluster 3) qui dépensent des centaines de milliers de livres, créant des valeurs extrêmes difficiles à prédire précisément
- **MAE = 688£** : l'erreur médiane est plus raisonnable, confirmant que le RMSE est tiré vers le haut par quelques outliers

9 Prédiction et Déploiement des Modèles

9.1 Architecture du Script `predict.py`

Le script `predict.py` constitue l'interface de production des modèles entraînés. Il charge les trois artefacts sauvegardés et expose des fonctions de prédiction réutilisables pour une intégration dans une application web ou un pipeline décisionnel.

TABLE 11 – Modèles chargés par `predict.py`

Fichier	Modèle	Type
<code>models/best_classifier.pkl</code>	XGBClassifier	Classification (Churn)
<code>models/best_regressor.pkl</code>	RandomForestRegressor	Régression (MonetaryTotal)
<code>models/kmeans_model.pkl</code>	KMeans (k=4)	Clustering (Segmentation)

TABLE 12 – Pipeline d'exécution de `predict.py`

Étape	Description	Entrée	Sortie
1	Chargement des modèles	<code>models/*.pkl</code>	3 objets Python
2	Récupération colonnes référence	<code>X_train.csv</code>	Listes de colonnes
3	Fonctions de prédiction	DataFrame client	Prédictions
4	Démonstration sur test	<code>X_test.csv</code> (875)	Rapport complet
5	Génération rapport combiné	Toutes prédictions	<code>predictions.csv</code>
6	Prédiction unitaire	Valeurs normalisées	Résultat individuel

TABLE 13 – Modèles chargés par `predict.py`

Fichier	Modèle	Type
<code>models/best_classifier.pkl</code>	XGBClassifier	Classification (Churn)
<code>models/best_regressor.pkl</code>	RandomForestRegressor	Régression (MonetaryTotal)
<code>models/kmeans_model.pkl</code>	KMeans (k=4)	Clustering (Segmentation)

TABLE 14 – Pipeline d'exécution de `predict.py`

Étape	Description	Entrée	Sortie
1	Chargement des modèles	<code>models/*.pkl</code>	3 objets Python
2	Récupération colonnes référence	<code>X_train.csv</code>	Listes de colonnes
3	Fonctions de prédiction	DataFrame client	Prédictions
4	Démonstration sur test	<code>X_test.csv</code> (875)	Rapport complet
5	Génération rapport combiné	Toutes prédictions	<code>predictions.csv</code>
6	Prédiction unitaire	Valeurs normalisées	Résultat individuel

9.1.1 Seuils de Risque Churn

La fonction `predict_churn` catégorise la probabilité de départ selon quatre niveaux de risque opérationnels :

TABLE 15 – Seuils de risque Churn

Niveau	Seuil probabilité	Signification
Faible	< 0.25	Client stable, peu de risque
Moyen	0.25 – 0.50	Surveillance recommandée
Élevé	0.50 – 0.75	Intervention conseillée
Critique	> 0.75	Action immédiate requise

Note sur `predict_monetary`

Les valeurs négatives prédites sont clippées à 0 via `np.maximum(predictions, 0)`. Dans le jeu de données d'entraînement, les montants négatifs correspondent à des remboursements historiques, phénomène non prédictible pour un futur client sans historique d'achat.

9.2 Résultats sur le Jeu de Test (875 Clients)

9.2.1 Résultats de la Classification

Le modèle XGBoost atteint une accuracy de 99.77% sur l'ensemble de test.

TABLE 16 – Distribution des prédictions de churn

Classe	Libellé	Nombre	Pourcentage
0	Fidèle prédit	586	67.0%
1	Churné prédit	289	33.0%
Total		875	100%

TABLE 17 – Distribution des niveaux de risque

Niveau	Nombre	Pourcentage
Faible	585	66.9%
Moyen	1	0.1%
Critique	289	33.0%




FIGURE 9 – Distribution des niveaux de risque Churn sur les 875 clients de test




FIGURE 10 – Distribution des probabilités de churn — concentration aux extrêmes (nature synthétique du dataset)

Observation — Distribution Binaire des Risques

Le modèle est très binaire : 99.9% des clients sont classés en niveau *Faible* ou *Critique*, avec un seul client en zone *Moyen*. Cette concentration aux extrêmes confirme la nature synthétique du dataset, où le Churn a été généré de façon déterministe par une formule mathématique. Dans un contexte réel de e-commerce, la distribution serait plus étalée sur les quatre niveaux de risque, avec davantage de cas ambigus.

9.2.2 Résultats de la Segmentation

Le clustering K-Means identifie quatre segments clients cohérents avec les profils RFM.

TABLE 18 – Distribution des segments clients

Segment	Nombre	Pourcentage	Profil
Réguliers	642	73.4%	Comportement moyen équilibré
Dormants	221	25.3%	Inactifs, risque churn élevé
Champions	11	1.3%	Très actifs, dépenses élevées
VIP	1	0.1%	Ultra-premium




FIGURE 11 – Distribution des segments clients K-Means sur les 875 clients de test

9.2.3 Résultats de la Régression

Le modèle Random Forest Regressor prédit le montant total dépensé avec un R^2 de 0.6855 sur l'ensemble d'entraînement.

TABLE 19 – Statistiques des montants prédits

Statistique	Valeur
Minimum	0.00 £
Médiane	0.00 £
Moyenne	153.60 £
Maximum	1645.93 £




FIGURE 12 – Distribution des montants prédits par segment (clients avec montant > 0£)

Observation — Médiane à 0£

La médiane à 0.00£ indique que plus de 50% des clients ont un montant prédit très faible (clippé à zéro). Le modèle Random Forest ($R^2=0.6855$) est plus précis sur les gros montants (segments Champions et VIP) que sur les petits clients. Cette caractéristique est cohérente avec la nature des données : les clients à faible activité sont plus difficiles à modéliser.


9.3 Comparaison Churn Réel vs Prédit

FIGURE 13 – Comparaison churn réel vs prédit — distributions quasi-identiques confirmant l'accuracy de 99.77%

Les diagrammes circulaires montrent une quasi-identité entre la distribution réelle du churn et celle prédite par le modèle, avec respectivement 33.3% de churnés dans les données réelles et 33.0% dans les prédictions.

9.4 Rapport Combiné — Extrait predictions.csv

Le script génère un fichier `predictions.csv` contenant l'ensemble des prédictions pour les 875 clients de test.

TABLE 20 – Extrait des prédictions (10 premiers clients)

Client	Churn Réel	Churn Prédit	Probabilité	Risque	Montant £	Segment
0	0	0	0.22%	Faible	0.00	Réguliers
1	0	0	0.14%	Faible	0.00	Réguliers
2	1	1	99.94%	Critique	0.00	Dormants
3	0	0	0.21%	Faible	0.00	Réguliers
4	1	1	96.83%	Critique	853.02	Réguliers
5	0	0	0.04%	Faible	0.00	Réguliers
6	1	1	99.97%	Critique	0.00	Dormants
7	1	1	99.95%	Critique	0.00	Dormants
8	0	0	1.77%	Faible	853.02	Réguliers
9	0	0	0.21%	Faible	851.55	Réguliers

Observations sur l'extrait

- **Client 2** : Dormant avec 99.94% de probabilité de churn — cohérence parfaite entre segmentation et classification.
- **Client 4** : Churné mais classé Régulier — un client au comportement régulier peut néanmoins partir, illustrant que la fidélité passée ne garantit pas la fidélité future.
- **Clients 8-9** : Fidèles avec 853£ de montant prédit — clients rentables à conserver absolument, cibles prioritaires pour des actions de fidélisation.

9.5 Exemple de Prédiction pour un Nouveau Client

Le script permet également de prédire pour un client fictif dont les caractéristiques ont été normalisées avec le **StandardScaler** sauvegardé.

TABLE 21 – Caractéristiques du nouveau client (valeurs normalisées)

Feature	Valeur normalisée
Recency	-0.4 (actif récemment)
Frequency	0.2
FirstPurchaseDaysAgo	-0.3 (client récent)

TABLE 22 – Résultats de prédiction pour le nouveau client

Indicateur	Valeur
Churn prédit	Churné (1)
Probabilité	90.6%
Niveau de risque	Critique
Montant prédit	3.92 £
Segment	Réguliers

Analyse — Nouveau Client à Risque Critique

Malgré une activité récente (**Recency** = -0.4, soit inférieur à la moyenne) et un premier achat récent (**FirstPurchaseDaysAgo** = -0.3), le modèle prédit un churn critique à 90.6%. Cette prédiction s'explique par l'importance des features **CustomerType_Occasionnel** (18.7%) et **Frequency** (15.6%) dans le modèle XGBoost. Un client avec peu de factures (**Frequency** légèrement positive) et sans historique de fidélisation est systématiquement perçu comme à risque de départ, même s'il vient d'effectuer un achat.

9.6 Limites et Recommandations pour le Déploiement

9.6.1 Limites Identifiées

TABLE 23 – Limites du système de prédiction

Limite	Cause	Impact
Prédictions très binaires	Dataset synthétique	Peu de zones grises, décisions binaires
Médiane régression = 0£	Sous-estimation petits clients	Imprécision pour clients modestes
Valeurs normalisées requises	StandardScaler appliqué	Preprocessing obligatoire en production

9.6.2 Recommandations pour le Déploiement en Production